ECOLE MAROCAINE DES SCIENCES DE L'INGENIEUR
Membre de HONORIS UNITED UNIVERSITIES

HONORIS UNITED UNIVERSITIES

Rapport de Projet d'IA distribuée et système multi-agents

4ème année
IASDR Group 4

Sous le thème

Learning Log

Réalisé par :

Lahbichi Alae

Benladoul Hyathame

Encadré par :

Chaabi Hasnaa

Année Universitaire :2025-2026

TABLE DES MATIÈRES

TABLE DES MATIÈRES ..... *II*

INTRODUCTION GENERALE *3*

I. L'échec du RAG natif dans n8n **4**

II. Coordination Multi-Agents & Structure de Réponse **5**

III. Contraintes de Ressources (Crédits & Modèles) **6**

IV. Synchronisation Interface Web et Latence API **7**

V. Limitation des Ressources (Crédits & Génération d'Images) **8**

INTRODUCTION GENERALE

Dans le cadre du développement de notre **Assistant d'Aide à l'Enseignement Primaire**, ce Learning Log (Journal d'Apprentissage) ne se limite pas à un simple compte-rendu de tâches. Il constitue un outil d'ingénierie intellectuelle conçu pour documenter la manière dont nous modélisons et résolvons les problèmes complexes inhérents aux systèmes multi-agents (SMA). L'approche adoptée ici repose sur la méthode CHAABI (C2PCT), un cadre structurant qui permet de transformer chaque "bug" ou blocage technique en une opportunité d'apprentissage profond. Ce document retrace notre parcours à travers quatre dimensions fondamentales :

1. Le Cadrage Cognitif : Pour identifier précisément nos "points aveugles" face aux outils comme n8n et aux architectures RAG.

2. Le Problem-Solving : Pour décomposer les défis d'extraction de données et de coordination d'agents en sous-problèmes gérables.

3. Le Computational Thinking : Pour formuler des hypothèses logiques, tester des stratégies hybrides (comme l'intégration de Flask) et corriger nos trajectoires techniques.

4. La Capitalisation : Pour synthétiser les solutions trouvées et anticiper les futurs besoins du système.

À travers ce suivi rigoureux, nous démontrons comment nous avons surmonté des obstacles critiques — tels que les limitations budgétaires des API propriétaires et les difficultés de synchronisation des données — en basculant vers des architectures locales performantes (Ollama) et des pipelines de données structurés. Ce journal témoigne de notre progression, non seulement en tant que développeurs, mais en tant que concepteurs de solutions IA responsables et optimisées.

I. L'échec du RAG natif dans n8n

Phase	Sous-catégorie	Description / Détails
(C) Cadrage Cognitif	**Apprentissage exploré**	Mise en œuvre d'un pipeline RAG pour l'extraction d'activités pédagogiques depuis des PDF (Google Drive).
	Difficulté / Point aveugle	L'Agent IA de n8n ignore le *Retriever* et produit des réponses génériques sans exploiter le contexte de la base vectorielle.
(P) Problem-Solving	**Décomposition**	1. Extraction (Drive) → 2. Embedding & Stockage (ChromaDB/Pinecone) → 3. Requêtage via l'Agent.
	Patterns	"Déconnexion" entre le LLM et ses outils : l'IA ignore l'outil par paresse si le prompt système n'est pas assez directif.
	Abstraction	Distinction entre la donnée utile (contenu du PDF) et le "bruit" technique lié à l'interface n8n.
(CT) Computational Thinking	**Hypothèse**	L'externalisation de la logique de récupération vers un script Flask permet un contrôle total de la recherche de similarité.
	Stratégie adoptée	Développement d'une API Flask (LangChain/Ollama) interrogeant la base vectorielle et renvoyant le contexte à n8n par HTTP.
	Amélioration	Réduction de la latence et capacité de déboguer précisément le contexte transmis au modèle avant la génération finale.

II. Coordination Multi-Agents & Structure de Réponse

Phase	Sous-catégorie	Description / Détails
(C) Cadrage Cognitif	**Apprentissage exploré**	Orchestration d'un système Multi-Agent (Générateur, Organisateur, Solveur).
	Difficulté / Point aveugle	Inconsistance des formats de réponse : l'envoi de texte brut au lieu de JSON provoque l'échec de l'interface web en fin de chaîne.
(P) Problem-Solving	**Décomposition**	1. Agent Générateur (Contenu) → 2. Agent Organisateur (Structure) → 3. Agent Solveur (Test/Simulation).
	Patterns	Analogie avec la Medallion Architecture (Data Pipeline) : passage du Bronze (brut) vers le Gold (prêt pour l'UI).
	Abstraction	Focalisation exclusive sur le dictionnaire final { "titre": "...", "étapes": [...] }, faisant abstraction du verbiage intermédiaire.
(CT) Computational Thinking	**Hypothèse**	Utilisation de schémas de sortie stricts (Pydantic/JSON Mode) pour forcer la synchronisation inter-agents.
	Stratégie adoptée	Imposition d'un "Prompt de Sortie" restrictif exigeant uniquement le format JSON attendu.
	Amélioration	Insertion d'un nœud de "Nettoyage de code" post-n8n pour purger les balises Markdown (```json) et sécuriser le parsing.

III. Contraintes de Ressources (Crédits & Modèles)

Phase	Sous-catégorie	Description / Détails
(C) Cadrage Cognitif	**Apprentissage exploré**	Optimisation des coûts de déploiement d'une IA.
	Difficulté / Point aveugle	Épuisement des crédits API (OpenAI/Claude) bloquant l'usage de modèles haut de gamme.
(P) Problem-Solving	**Décomposition**	Segmentation des besoins : distinguer les agents nécessitant de la puissance de ceux pouvant tourner en local (SLM).
	Patterns	Adoption d'une approche "Edge Computing" ou "Local-first AI".
	Abstraction	Gestion de l'intelligence comme une ressource finie : le modèle puissant est réservé à la validation finale.
(CT) Computational Thinking	**Hypothèse**	Remplacement des API payantes par des modèles locaux (Llama 3, Mistral) via Ollama durant le développement.
	Stratégie adoptée	Mise en place de tunnels **ngrok** pour relier n8n à l'instance locale Ollama sans coût de jetons.
	Amélioration	Substitution de DALL-E par des "fiches illustrées" (caractères spéciaux/icônes), réduisant le budget image à zéro.
(C) Capitalisation	**Références**	Documentation n8n (AI Agents), Framework Bebras (logique débranchée), Documentation Flask (API REST).
	Question ouverte	Mise en œuvre de **WebSockets** pour le suivi en temps réel de l'avancement des agents (streaming d'état).

IV. Synchronisation Interface Web et Latence API

Phase	Sous-catégorie	Description / Détails
(C) Cadrage Cognitif	**Apprentissage exploré**	Communication asynchrone entre orchestration (n8n/Flask) et interface utilisateur.
	Difficulté / Point aveugle	Interface figée ou en timeout due à la longueur des chaînes d'agents (Extraction → Création → Organisation).
(P) Problem-Solving	**Décomposition**	1. Envoi requête → 2. Suivi d'état (Polling/WebSockets) → 3. Rendu final des données.
	Patterns	Analogie avec les comparateurs de vols : affichage progressif au lieu d'une page blanche statique.
	Abstraction	Transformation du flux JSON technique en indicateurs visuels de progression pour l'utilisateur.
(CT) Computational Thinking	**Hypothèse**	Fragmentation de la réponse et utilisation de webhooks intermédiaires pour des mises à jour en temps réel.
	Stratégie adoptée	Utilisation de Flask comme "tampon" (buffer) : n8n notifie Flask de la fin de chaque tâche d'agent via POST.
	Amélioration	Implémentation de Loading States contextuels ("L'Agent Créateur analyse...", etc.) pour réduire la frustration de l'attente.

V. Limitation des Ressources (Crédits & Génération d'Images)

Phase	Sous-catégorie	Description / Détails
(C) Cadrage Cognitif	**Apprentissage exploré**	Stratégies de contournement et optimisation budgétaire pour le développement IA.
	Difficulté / Point aveugle	L'absence de crédits pour la génération d'images (DALL-E) réduit l'attrait visuel de l'outil pour un public de primaire.
(P) Problem-Solving	**Décomposition**	1. Remplacement des modèles payants par du local. 2. Recherche d'alternatives gratuites pour l'illustration.
	Patterns	"Degradation Graceful" : maintien d'une expérience fonctionnelle via des alternatives gratuites en cas de contrainte technique.
	Abstraction	Priorisation de l'aspect ludique (émojis/icônes/mise en page) sur le photoréalisme coûteux de l'IA générative.
(CT) Computational Thinking	**Hypothèse**	Utilisation de modèles Open Source locaux pour le raisonnement et de banques d'icônes pour le visuel.
	Stratégie adoptée	Migration des agents secondaires vers **Llama 3 (Ollama)**. Sélection par l'IA d'icônes SVG/émojis thématiques au lieu d'images générées.
	Amélioration	Concentration du budget "crédits" sur l'agent **Créateur** seul, préservant la finesse pédagogique là où elle est critique.
(C) Capitalisation	**Références**	Documentation Ollama, Framework Bebras (logique débranchée), Patterns asynchrones FastAPI/Flask.

Questions ouvertes	Risque de simplification excessive par les modèles locaux (Méthode CHAABI) et faisabilité de **Stable Diffusion** en local via Flask.